TRABAJO FINAL

Detección de Fraude en Seguros de Automóvil

Curso 2025-2026

Clasificación supervisada con scikit-learn Pipelines

1. Contexto de negocio

Trabajáis como equipo de Data Science en **AutoGuard Seguros**, una aseguradora de automóvil que opera en España. La compañía procesa aproximadamente 15.000 siniestros anuales. Actualmente, todos los siniestros pasan por un sistema de triaje automatizado y, en función del resultado, algunos escalan a revisión experta por un perito y eventualmente a la Unidad de Investigaciones Especiales (SIU).

El proceso actual es costoso y reactivo: la decisión de investigar se toma *después* de que el siniestro ya ha avanzado por varias rondas de revisión. La dirección de AutoGuard quiere un modelo predictivo que, **en el momento de recepción del siniestro** (es decir, usando únicamente información disponible en la fecha de `claim_datetime`), sea capaz de estimar la probabilidad de que ese siniestro sea fraudulento, con el fin de decidir si merece la pena enviar un perito a investigar.

2. Datos proporcionados

Se entregan **5 ficheros CSV** que conforman un modelo relacional de la operativa de AutoGuard:

Fichero	Granularidad	Descripción
claims.csv	1 fila = 1 siniestro	Tabla principal: fechas, importes, circunstancias
policies.csv	1 fila = 1 póliza	Información contractual de cada póliza
customers.csv	1 fila = 1 asegurado	Datos personales y demográficos
vehicles.csv	1 fila = 1 vehículo	Información del vehículo asegurado
claim_reviews.csv	1 fila = 1 revisión	Auditorías y revisiones de cada siniestro

2.1. Descripción de claim_reviews.csv

Un cliente puede tener varias pólizas; una póliza puede tener varios siniestros y varios vehículos asociados; cada siniestro puede tener entre 1 y 3 rondas de revisión.

Esta tabla contiene el historial de auditorías. Cada siniestro tiene entre 1 y 3 filas (una por ronda de revisión):

- **Ronda 1 — Triaje inicial:** se asigna un `auto_risk_score` (0-100) y un `triage_result` categórico (Green/Yellow/Orange/Red). Todos los siniestros tienen esta ronda.
- **Ronda 2 — Evaluación experta:** un perito (`perito_id`) puede hacer inspección física (`perito_physical_inspection`), y se registran un `damage_consistency_rating` (1-5, donde 5 = totalmente consistente) y un `documentation_completeness_pct` (0-100%). Solo ~57% de los siniestros llegan a esta ronda.
- **Ronda 3 — Investigación SIU:** resolución final del caso con un `recommended_action` categórico. Solo ~13% de los siniestros llegan aquí.

3. Construcción del target

No se proporciona una variable target precalculada. Debéis construirla a partir de la tabla `claim_reviews`, siguiendo la definición operativa de fraude que utiliza el departamento de Cumplimiento de AutoGuard.

> **Un siniestro se etiqueta como fraudulento (`fraud_flag = 1`) cuando se cumple AL MENOS UNA de las siguientes condiciones:**

> **Condición A — Resolución negativa en SIU (Ronda 3):**
>
> El siniestro tiene una fila con `review_round = 3` y el campo `recommended_action` toma uno de estos valores: `Claim Denied`, `Claim Withdrawn by Claimant`, o `Pending Litigation`.

> **Condición B — Evaluación experta desfavorable (Ronda 2):**
>
> En la ronda 2 (`review_round = 2`), el campo `recommended_action` es `Recommend Denial` o `Refer to Special Investigations Unit`, **Y** simultáneamente `damage_consistency_rating` es estrictamente menor que `3.0`.

> **Condición C — Triaje severo confirmado por perito (Rondas 1 + 2):**
>
> En la ronda 1 (`review_round = 1`), el `triage_result` es `Red - Full Investigation`, **Y** en la ronda 2 del mismo siniestro, `perito_physical_inspection` es `Yes` **Y** `documentation_completeness_pct` es estrictamente menor que `65`.

> Cualquier siniestro que no cumpla ninguna de las tres condiciones se etiqueta como `fraud_flag = 0`.

> **Verificación:** si la construcción es correcta, deberíais obtener aproximadamente un **7 % de siniestros positivos**.

4. Problema de negocio

Actualmente, cuando AutoGuard recibe un siniestro, lo tramita y lo paga sin investigación adicional salvo que el sistema de triaje interno lo escale. El coste medio de un siniestro fraudulento que se paga íntegramente es de **2.680 €**. La compañía quiere utilizar el modelo predictivo para decidir, en el momento de la recepción de cada siniestro, si envía un perito a investigar o no.

Para cada siniestro, el modelo produce una probabilidad de fraude $\hat{p}$. Si $\hat{p}$ supera un umbral θ, se envía un perito a investigar. Si no, el siniestro se tramita y paga con normalidad. El objetivo es encontrar el umbral θ que minimice el coste total para la compañía.

4.1. Parámetros económicos

Parámetro	Valor	Descripción
C_perito	350 €	Coste de enviar un perito a investigar un siniestro
C_fraude	2.680 €	Coste medio de un siniestro fraudulento que se paga íntegramente sin detectar
R_deteccion	2.680 €	Recuperación cuando el perito confirma el fraude (se evita el pago completo)

4.2. Matriz de costes

El coste de cada siniestro depende de la combinación entre la decisión tomada (enviar perito o no) y la naturaleza real del siniestro (fraude o legítimo):

	Siniestro legítimo (y = 0)	Siniestro fraudulento (y = 1)
No se envía perito	0 €	2.680 € (se paga el fraude)
Se envía perito	350 € (coste del perito, innecesario)	350 € (coste del perito, se evita pagar el fraude)

Dicho de otra forma:

- **Verdadero negativo** (legítimo, no se envía perito): coste **0 €**. Tramitación normal, resultado correcto.
- **Falso positivo** (legítimo, se envía perito): coste **350 €**. Se gasta en un perito que no encuentra nada.
- **Falso negativo** (fraude, no se envía perito): coste **2.680 €**. Se paga íntegramente un siniestro fraudulento.
- **Verdadero positivo** (fraude, se envía perito): coste **350 €**. Se paga el perito pero se evita pagar el fraude.

Sin modelo, AutoGuard no envía perito a ningún siniestro. El coste base es simplemente el número de siniestros fraudulentos multiplicado por 2.680 € (todos los fraudes pasan desapercibidos). La diferencia entre este coste base y el coste con modelo es el **ahorro neto** que genera el sistema.

5. Requisitos técnicos

Todo el preprocesamiento y modelado debe estar encapsulado en un `sklearn.pipeline.Pipeline` (o `ColumnTransformer` + `Pipeline`). El pipeline debe poder recibir un dataframe crudo (sin usar claim_reviews) de un nuevo siniestro y devolver una predicción sin intervención manual.

Debes encontrar la métrica óptima para optimizar el problema económico. Recuerda que la decisión del modelo se considera definitiva y sirve para decidir si se envía a un perito a revisar o no.

6. Entregables

Las diapositivas a presentar el día de la presentación.

1. **Deben explicar a alto nivel la solución técnica y centrarse más en el análisis económico**
2. **Máximo tiempo de presentación 10 min (estricto).**

Una memoria técnica que incluya:

3. **Resumen ejecutivo:** qué se ha construido, qué métricas tiene, qué experimentos has realizado, pipeline+hiperparámetros finales...
4. **Impacto económico estimado:** comparativa coste sin modelo vs. coste con modelo, proyectado al volumen anual.

Un notebook reproducible y bien documentado que contenga:

5. **Carga y exploración:** lectura de los 5 CSV, análisis exploratorio, verificación de la construcción del target.
6. **Feature engineering:** proceso completo de joins, variables derivadas y agregados, justificando decisiones.
7. **Pipeline de modelado:** código completo del pipeline en scikit-learn.
8. **Entrenamiento y evaluación:** al menos dos modelos, comparación con métricas apropiadas.
9. **Optimización de umbral:** búsqueda del punto de corte óptimo basada en la matriz de costes.
10. **Análisis de errores:** exploración de los falsos positivos y falsos negativos más significativos.

7. Criterios de evaluación

Criterio	Peso
Memoria + Notebook	30%
Presentación oral (Máx 10 min)	30%
Ranking	40%

El dataset holdout para la inferencia se subirá al campus poco antes de la fecha de entrega.
El ranking se realizará en base a impacto económico, es decir, debes seleccionar la métrica más adecuada en tu modelo de clasificación de forma que el dinero ahorrado neto sea el máximo posible.

Para la comparación se usará el escenario sin modelo como comparativa. Por ejemplo, un caso donde ha habido 1000 fraudes, tendrá un coste de 2.68M€.
Si nuestro modelo tiene 300 falsos positivos y 200 verdaderos positivos, de un total de 500 decisiones de enviar a un perito, el resultado será:

Resultado neto: 200x2680 (ahorro por acierto) - 500x350 (coste de los peritos) = 361K € de ahorro neto respecto al escenario base.